한국어 학습자 작문의 숙달도 자동 예측 및 모어별 오차 분석

자연어처리 Term Project #1 (Automated Essay Scoring) · 이재영 (학번: 1102643012) · 2026. 10. 23.

요약

본 프로젝트에서는 국립국어원 한국어 학습자 말뭉치를 이용하여, 학습자가 작성한 문장으로부터 작성자의 한국어 급수(1–6급)를 예측하였다. 공개 검색 서비스를 통해 문어 자료 28,971문장(18,909개 글, 75개 모어)을 급수별로 고르게 표집하였고, 형태소 분석 기반 언어 특징 25개와 문자·형태소 n-gram을 각각 Ridge 회귀에 적용하여 비교하였다. 학습자 단위 5-fold 교차검증 결과, n-gram 모델의 QWK가 0.642(±1급 정확도 78.6%)로 가장 높았으며, 길이만 사용한 기준 모델은 0.182, 언어 특징 모델은 0.412였다. 급수가 높을수록 문장 길이와 조사 종류가 늘었고, 종결 문체는 2급과 3급 사이에서 해요체·합니다체 중심에서 한다체 중심으로 바뀌었다. 모어별로는 몽골어와 우즈베크어 학습자가 평균 0.7–0.8급 높게 예측되었으나, 급수 분포를 보정하면 차이가 대부분 사라졌다. 이는 모어 자체보다 양 끝 급수를 중간으로 예측하는 경향에서 비롯된 것으로 해석된다. 한편 해당 모어를 학습에서 제외하면 QWK가 0.586에서 0.501로 낮아져, 작성자 집단이 달라질 때 성능이 떨어지는 현상을 확인하였다. 또한 같은 1급이라도 국외 학습자는 국내 학습자보다 약 0.7급 높게 예측되어, 급수 라벨의 기준이 학습 환경에 따라 다를 가능성이 있음을 확인하였다.

1. 서론

자동 글쓰기 평가(Automated Essay Scoring, AES)는 사람 채점자의 판단을 재현하는 기술이다. 표면 특징과 선형 회귀를 쓰던 1세대(Page, 1966; Attali & Burstein, 2006), 신경망이 특징 설계를 대신한 2세대(Taghipour & Ng, 2016; Dong et al., 2017), 루브릭과 LLM으로 점수와 근거를 함께 만드는 3세대(Mizumoto & Eguchi, 2023; Lee et al., 2024)로 발전해 왔다. 다만 학습 데이터와 주제나 작성자 집단이 다른 글에서는 성능이 낮아지는 문제가 여전히 보고되고 있다(Li & Ng, 2024).

본 프로젝트에서 사용한 국립국어원 한국어 학습자 말뭉치는 여러 언어권의 성인 학습자가 작성한 글로 구성되어 있으며, 각 글에는 점수 대신 작성자의 한국어 급수(1–6급)가 부여되어 있다. 따라서 본 과제는 글의 점수를 예측하는 일반적인 AES와 달리, 글을 통해 작성자의 숙달도를 추정하는 문제에 가깝다. 또한 이 말뭉치에는 작성자의 모어(L1)와 학습 환경(국내/국외) 정보가 함께 제공된다. 이를 활용하면 예측 오차가 모어나 학습 환경에 따라 달라지는지도 확인할 수 있다.

본 보고서에서는 다음 네 가지를 살펴보았다.

- **RQ1.** 문장 단위 입력으로 학습자의 급수를 어느 정도 예측할 수 있는지, 그리고 언어 특징과 n-gram 중 어떤 표현이 적합한지
- **RQ2.** 급수에 따라 어떤 언어적 특징이 달라지는지
- **RQ3.** 모어와 학습 환경에 따라 예측 오차에 체계적인 차이가 있는지
- **RQ4.** 학습 데이터에 포함되지 않은 모어의 학습자에게도 모델이 비슷한 성능을 보이는지

2. 방법

2.1 데이터 수집과 전처리

데이터는 국립국어원 한국어 학습자 말뭉치를 공개 검색 서비스(한국어 학습자 말뭉치 나눔터, 원시 말뭉치 검색)를 통해 문장 단위로 표집하여 구축하였다. 검색 결과의 각 행은 모어, 급수, 학습 환경, 표본 ID와 함께 검색어 앞뒤의 문맥을 제공하며, 이를 이어 붙이면 학습자가 작성한 한 문장이 된다. 글 전체가 아닌 문장 표본을 사용하였으므로 본 연구의 분석 단위는 문장이다.

- 대상: 문어(쓰기) 자료, 급수 1–6급('6급~'과 '정보 없음'은 제외). 급수별로 따로 검색하였다.

- 검색어: 급수와 관계없이 자주 쓰이는 어절 18개(예: 있습니다., 그래서, 저는, 때문에, 한다.).
- 표집: 검색어와 급수의 조합마다 결과 페이지(100행) 3개를 무작위로 선택하였다. 검색 결과가 모어 가나다순으로 정렬되므로, 앞쪽 페이지만 사용하면 특정 모어가 과대 표집된다. 실제로 첫 수집에서는 러시아어 7,197문장, 중국어 238문장으로 분포가 크게 치우쳐 무작위 페이지 선택으로 변경하였다.
- 정제: 표본 ID와 문장 번호 기준 중복 제거, 5자 미만 문장과 동일 문장 제거.

최종 데이터는 28,971문장, 18,909개 글(표본), 75개 모어이며, 급수별로 4,032–5,185문장이다(그림 1). 학습 환경은 국내 19,803문장, 국외 9,168문장이다.

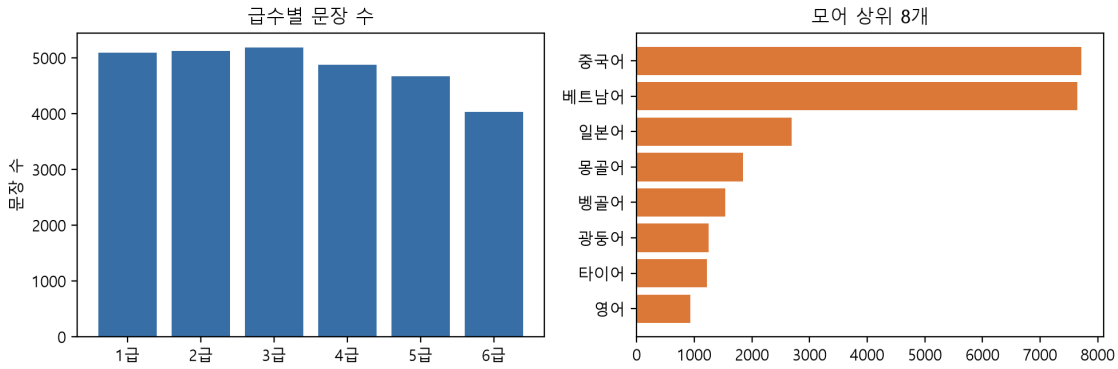


그림 1. 급수별 문장 수와 상위 8개 모어의 문장 수.

2.2 모델

모든 실험은 GPU 없이 CPU 환경에서 수행하였다. 각 모델은 급수를 연속값으로 예측하는 회귀 모델이며, 평가 시에는 예측값을 반올림하여 1–6 범위로 제한하였다.

모델	입력 표현	회귀기
M0 길이 baseline	어절 수, 글자 수	Ridge (α=1)
M1 언어 특징	Kiwi 형태소 분석 기반 특징 25개: 길이, 형태소 TTR, 조사 종류 수, 연결어미(EC)·관형형 전성어미(ETM)·명사형 전성어미(ETN)·보조용언(VX)·의존명사(NNB) 비율, 종결 문체(합니다/해요/한다), 절 수, 어휘 희귀도 등	Ridge / HistGradientBoosting
M2 n-gram	문자 1–3gram TF-IDF + 형태소/품사 1–2gram TF-IDF (min_df=2, sublinear tf)	Ridge (α=1)
M3 결합	M2 + M1 (표준화)	Ridge (α=1)

형태소 분석기: kiwipiepy 0.24.1. 라이브러리: scikit-learn 1.9.1, numpy 2.5.3, pandas 3.1.0, scipy 1.18.1, Python 3.12.10.

2.3 실험 설계와 평가

- 교차검증: 5-fold GroupKFold. 같은 글(표본)의 문장이 학습과 평가에 함께 포함되지 않도록 하였고, TF-IDF와 표준화는 폴드마다 학습 데이터로만 적합하였다. 비교를 위해 문장 단위 무작위 KFold 결과도 함께 제시한다.
- 지표: AES 표준 지표인 Quadratic Weighted Kappa(QWK), 정확도, ±1급 정확도(Adj±1), MAE, Spearman ρ.
- 글 단위 집계: 같은 글에서 문장 k개(k=1–4)의 예측을 평균했을 때의 성능을 측정하였다. 문장이 4개 이상 수집된 글만 사용하여 k에 관계없이 같은 글 집합을 비교하였고, 문장 선택은 20회 반복하여 평균하였다.
- 모어별 오차: 모어별 평균 오차(예측−실제)를 계산하였다. 모어마다 급수 분포가 다르기 때문에, 급수별 평균 오차를 전체 급수 분포로 가중 평균한 값(급 보정 오차)을 함께 제시한다. 학습 환경별 오차도 같은 방식으로 계산하였다.

- 특징 분석: 각 언어 특징과 급수 사이의 Spearman 상관을 계산하였다.
- 모어 제외 실험: 150문장 이상인 15개 모어에 대해, 해당 모어를 학습에서 제외한 모델(leave-one-L1-out)의 성능을 교차검증 결과와 비교하였다. 또한 같은 n-gram 특징으로 모어를 분류하는 실험(15개 모어, GroupKFold, 로지스틱 회귀)을 추가로 수행하였다.

코드: https://github.com/zmfozj1231-eng/korean-learner-aes (`src/collect.py` 수집, `src/features.py` 특징 추출, `src/run_experiments.py` 실험). 말뭉치 원문은 이용 약관에 따라 저장소에 포함하지 않았다.

3. 결과

3.1 급수 예측 성능 (RQ1)

모델	분할	QWK	Acc	Adj±1	MAE	Spearman
길이 baseline (Ridge)	학습자 단위	0.182	0.192	0.570	1.333	0.380
언어 특징 25개 (Ridge)	학습자 단위	0.401	0.233	0.675	1.191	0.506
언어 특징 25개 (GBM)	학습자 단위	0.412	0.234	0.686	1.172	0.520
문자+형태소 n-gram (Ridge)	**학습자 단위**	**0.642**	**0.346**	**0.786**	**0.960**	**0.687**
n-gram + 언어 특징 (Ridge)	학습자 단위	0.642	0.345	0.785	0.960	0.687
언어 특징 25개 (Ridge)	무작위(문장)	0.401	0.233	0.675	1.192	0.506
문자+형태소 n-gram (Ridge)	무작위(문장)	0.651	0.349	0.791	0.948	0.696
n-gram + 언어 특징 (Ridge)	무작위(문장)	0.651	0.350	0.791	0.948	0.696

표 1. 문장 단위 급수 예측 성능 (5-fold CV, 28,971문장). 굵은 글씨는 학습자 단위 분할에서의 최고 성능.

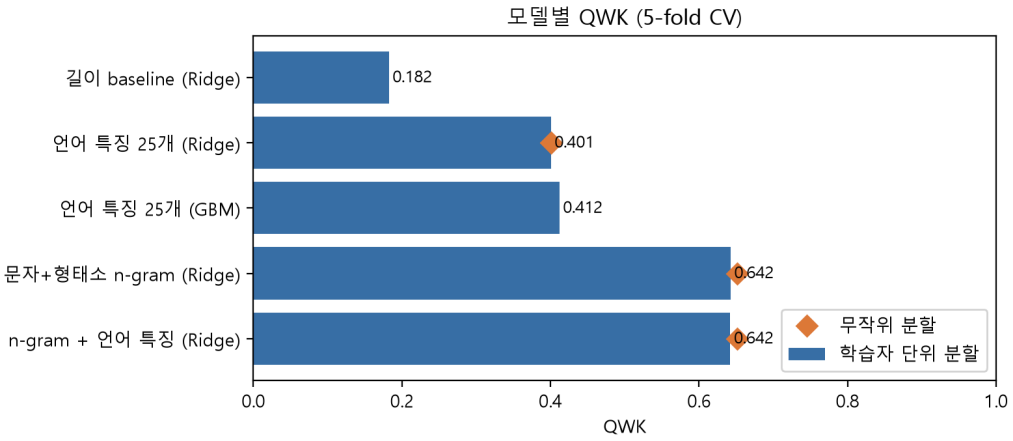


그림 2. 모델별 QWK. 마름모는 무작위 분할 결과.

입력 표현에 따라 성능 차이가 컸다. 길이만 사용한 기준 모델(QWK 0.182)도 우연 수준보다는 높았는데, 이는 글의 길이가 점수와 관련이 있다는 기존 관찰(Page, 1966)과 일치한다. 언어 특징 25개를 사용하면 QWK가 0.40 수준으로 올랐고, 문자·형태소 n-gram 모델이 0.642로 가장 높았다. n-gram에 언어 특징을 추가한 모델(0.642)은 n-gram 단독과 차이가 없었는데, 어미 종류나 문체 같은 정보가 이미 n-gram에 포함되어 있기 때문으로 보인다.

정확도는 34.6%로 6개 급수의 우연 수준(16.7%)보다 높았고, ±1급 정확도는 78.6%였다. 그림 3의 혼동행렬을 보면 예측이 2–5급에 집중되어 있으며, 1급(27%)과 6급(18%)의 정답률이 특히 낮다. 양 끝 급수가 중간으로 예측되는 경향은 수업에서 LLM 채점의 한계로 언급된 중간 점수 쏠림과 비슷한 형태이다.

문장 단위 무작위 분할의 QWK는 학습자 단위 분할보다 0.009 높았다. 이번 표본은 글 하나당 평균 1.5문장으로, 같은 글의 문장이 학습과 평가에 함께 들어갈 가능성이 낮아 차이가 작았던 것으로 보인다. 글 전체를 사용하는 경우에는 차이가 커질 수 있으므로 본 보고서는 학습자 단위 분할 결과를 기준으로 하였다.

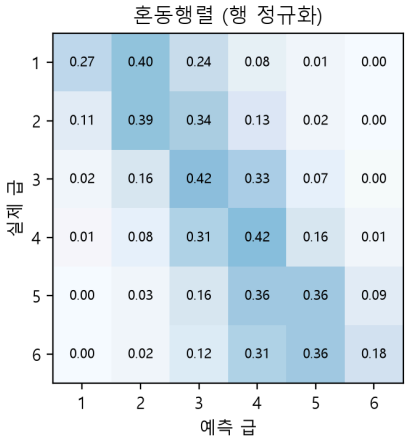


그림 3. 최고 모델(M2)의 혼동행렬 (행 정규화).

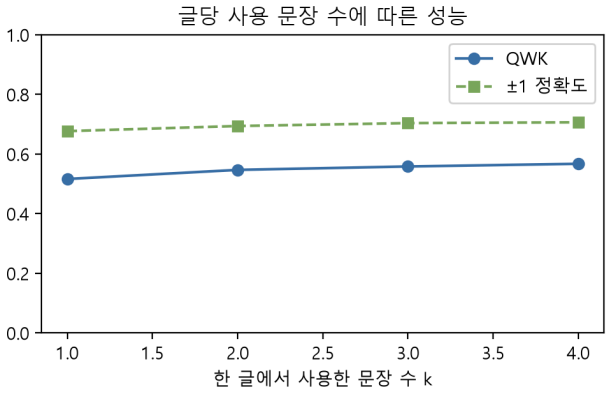


그림 4. 같은 글에서 문장 k개를 평균했을 때의 성능 (966개 글, 20회 평균).

한 글에서 사용하는 문장 수를 늘리면 성능이 완만하게 올랐다. 같은 966개 글에서 문장 1개를 사용했을 때 QWK는 0.516, 4개의 평균을 사용했을 때 0.567였다(Spearman 0.589, 0.696). 증가 폭은 문장 수가 늘수록 줄었는데, 같은 학습자의 문장끼리 비슷한 정보를 담고 있고 라벨 자체에도 오차가 있기 때문으로 생각된다.

3.2 급수에 따른 언어 특징 (RQ2)

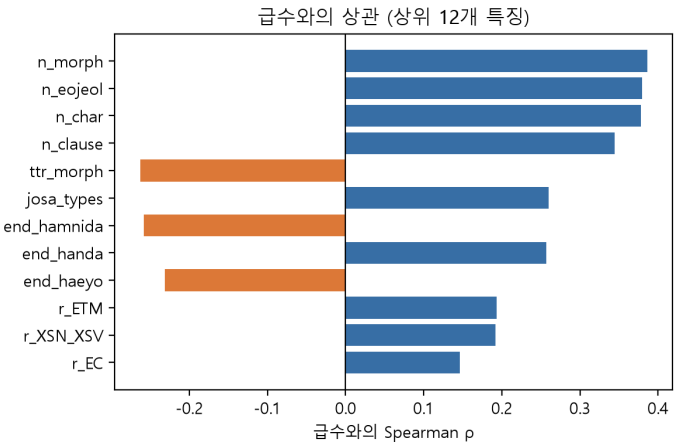


그림 5. 급수와 Spearman 상관이 큰 특징 12개.

특징	1급	3급	6급
어절 수 (ρ=+0.38)	7.3	9.81	13
조사 종류 수 (ρ=+0.26)	2.56	3.13	3.92
절 수(EC+ETM+1) (ρ=+0.34)	2.6	3.78	4.89
관형형 어미 비율 (ρ=+0.19)	0.0314	0.0485	0.0571
해요체 종결 (ρ=-0.23)	0.19	0.0411	0.0129
합니다체 종결 (ρ=-0.26)	0.614	0.417	0.252
한다체 종결 (ρ=+0.26)	0.116	0.38	0.474
형태소 TTR (ρ=-0.26)	0.943	0.909	0.879

표 2. 주요 특징의 급별 평균.

그림 5와 표 2는 급수에 따른 주요 특징의 변화를 보여 준다.

- 길이와 구조: 어절 수(7.3에서 13.0), 절 수, 관형형 어미 비율이 급수에 따라 꾸준히 증가하였다. 낮은 급수에서는 "저는 몽골에 삽니다."와 같은 단문이 많고, 높은 급수에서는 관형절과 연결어미를 사용한 복문이 많다.
- 조사: 문장당 조사 종류가 2.6개에서 3.9개로 늘었다(ρ=+0.26).
- 종결 문체: 해요체 종결 비율은 1급 19%에서 6급 1%로 줄고, 한다체는 12%에서 47%로 늘었다. 검색어 구성의 영향을 줄이기 위해 중립적인 검색어(그래서, 저는, 때문에 등)로 수집된 14,985문장만 따로 확인한 결과, 해요체는 36%에서 2%로, 한다체는 7%에서 62%로 바뀌어 같은 경향이 나타났다. 변화는 주로 2급

과 3급 사이에서 나타났다(한다체 23%에서 57%). 이 구간은 TOPIK I(1–2급)과 TOPIK II(3–6급)의 경계에 해당하며, TOPIK II 쓰기 영역에서 한다체 사용을 요구한다는 점을 고려하면 이 변화에는 교육 과정과 시험 형식의 영향도 포함되어 있다고 볼 수 있다.

- 어휘: 어휘 희귀도(코퍼스 내 빈도 순위)는 급수와 거의 상관이 없었고(ρ=+0.07), 형태소 TTR은 음의 상관을 보였다(ρ=−0.26). TTR은 문장이 길수록 낮아지는 경향이 있어, 문장 단위에서는 어휘 다양도가 길이의 영향을 크게 받는 것으로 보인다.

3.3 모어 및 학습 환경별 오차 (RQ3)

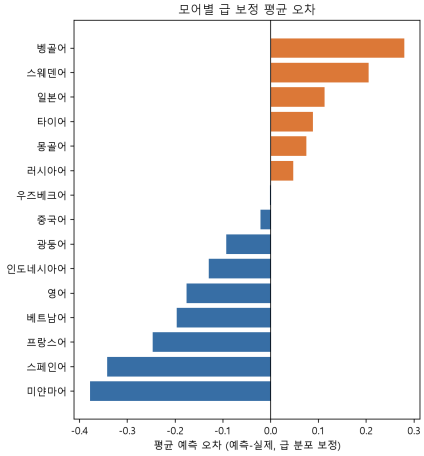


그림 6. 모어별 급 보정 오차.

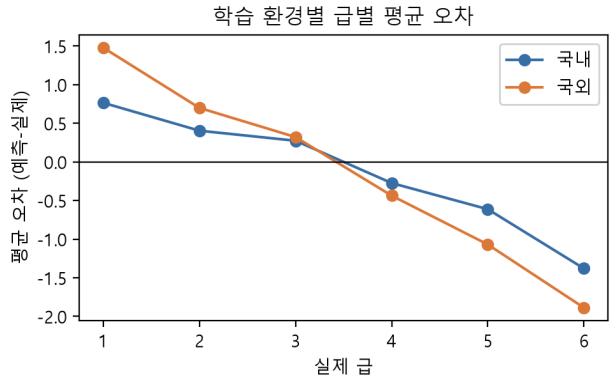


그림 7. 학습 환경별, 실제 급별 평균 오차.

모어	문장 수	평균 급	원시 오차	급 보정 오차	QWK
미얀마어	175	4.53	-1.07	-0.38	0.43
몽골어	1,848	2.46	+0.82	+0.07	0.43
우즈베크어	413	2.04	+0.71	-0.00	0.26
타이어	1,216	2.61	+0.66	+0.09	0.43
프랑스어	229	4.70	-0.51	-0.25	0.47
벵골어	1,535	2.00	+0.47	+0.28	0.06
러시아어	598	3.95	-0.43	+0.05	0.40

표 3. 원시 오차가 큰 모어의 원시 오차와 급 보정 오차.

모어별 원시 오차를 보면 몽골어(+0.82급), 우즈베크어(+0.71), 타이어(+0.66) 학습자는 높게, 미얀마어(−1.07) 학습자는 낮게 예측되었다. 그러나 이들 모어는 급수 분포가 한쪽에 치우쳐 있었다(예: 우즈베크어 평균 2.0급, 벵골어는 95%가 2급). 급수 분포를 보정하면 몽골어 +0.07, 우즈베크어 0.00, 타이어 +0.09로 차이가 대부분 사라졌다. 따라서 원시 오차의 상당 부분은 모어 자체의 영향이라기보다, 낮은 급수가 많은 집단은 높게, 높은 급수가 많은 집단은 낮게 예측되는 경향에서 비롯된 것으로 해석된다. 미얀마어(−0.38)와 스페인어(−0.34)는 보정 후에도 낮게 예측되었으나, 각각 200문장 안팎이어서 추가 확인이 필요하다.

학습 환경별로는 보정 후에도 차이가 남았다. 1급 학습자의 평균 오차는 국외 +1.48급, 국내 +0.76급이었고, 6급에서는 국외 -1.89급, 국내 -1.38급이었다(그림 7). 국외 학습자에서 양 끝 급수가 중간으로 예측되는 경향이 더 강했으며, 이는 국외 학습자의 급수 라벨이 글의 특성과 덜 일치함을 의미한다. 오차가 큰 사례(표 4)에서도 고급 문장을 작성한 국외 몽골어 1급 학습자가 여러 명 확인되었다. 기관마다 급수를 부여하는 기준이 다를 가능성이 있다.

실제	예측	모어	문장
1	6.0	몽골어	또한 생성형 AI인 챗봇은 고객 서비스를 향상하는 데 도움이 되고 있다.
1	5.9	우르두어	인구 증가율이 높아지면서 자원 부족, 교육과 보건 서비스의 부족, 그리고 경제 발전의 어려움이 심각한 문제로 대두되고 있습니다.
6	1.2	중국어	나는 나의 집을 진짜 좋아한다.
6	1.5	몽골어	저는 몽골에 삽니다.
6	1.4	베트남어	나는 종아하는 한국에서 삽니다.

표 4. 오차가 큰 사례. 위의 두 문장은 라벨 오류로 의심되는 경우이고, 아래 세 문장은 높은 급수의 학습자도 쉬운 문장을 쓸 수 있다는 문장 단위 입력의 한계를 보여 준다.

3.4 학습에 포함되지 않은 모어 (RQ4)

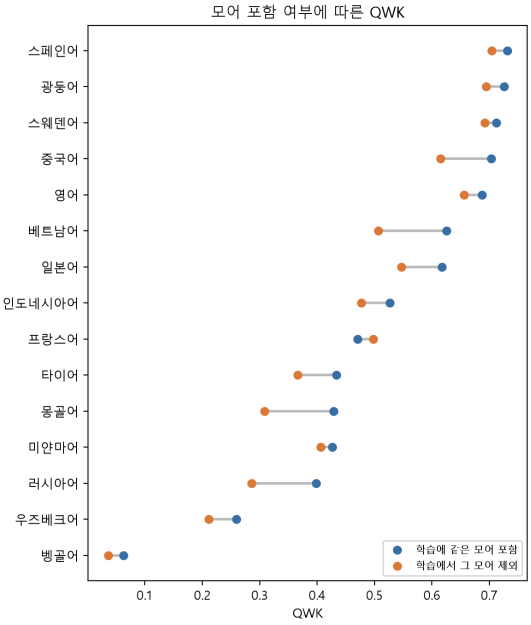


그림 8. 해당 모어가 학습 데이터에 포함된 경우와 제외된 경우의 QWK.

해당 모어를 학습에서 제외하면 성능이 낮아졌다. 15개 모어 전체(문장 수 가중 평균)의 QWK는 0.586에서 0.501로 떨어졌고, 하락 폭이 큰 모어는 몽골어(0.43, 0.31), 베트남어(0.63, 0.51), 러시아어(0.40, 0.29), 중국어(0.70, 0.62)였다. 몽골어와 타이어는 학습에서 제외했을 때 평균 오차가 각각 +0.82에서 +1.04, +0.66에서 +0.84로 커졌다. 반면 영어, 스페인어, 스웨덴어처럼 표본이 적은 모어는 변화가 작았는데, 원래도 대부분 다른 모어의 데이터로 학습된 상태였기 때문으로 보인다.

텍스트에 모어 정보가 어느 정도 남아 있는지 확인하기 위해, 같은 n-gram 특징으로 15개 모어를 분류하였다. 정확도는 53.2%로 다수 클래스 기준(28.2%)보다 높았다(macro-F1 0.30). 학습자의 문장에는 모어에 따른 표현상의 특징이 남아 있으며, 급수 예측 모델도 이러한 특징을 함께 학습했을 가능성이 있다. 이 때문에 학습에 없던 모어에서 성능이 낮아진 것으로 보인다. 수업에서 다룬, 주제가 달라지면 채점 성능이 떨어지는 문제와 비슷한 현상이 작성자 집단에 대해서도 나타난 것이다.

4. 논의

라벨의 성격. 이 데이터의 라벨은 글의 질이 아니라 작성자가 속한 급수이다. 따라서 높은 급수의 학습자가 쉬운 문장을 쓰면 낮게 예측될 수밖에 없다(표 4). 이러한 오차는 모델의 문제라기보다 과제 설정에서 오는 한계

이다. 교육 현장에서 활용하려면 글 단위 점수가 있는 데이터로 보정하거나 문장이 아닌 글 전체를 입력으로 사용할 필요가 있다. 문장 수를 늘릴수록 성능이 오른 결과(그림 4)도 같은 방향을 보여 준다.

급수 기준의 차이. 국외 학습자에서 양 끝 급수가 중간으로 예측되는 경향이 더 강했다는 것은, 기관마다 급수를 정하는 기준이 다를 수 있음을 보여 준다. QWK가 0.64 부근에 머문 원인 중 일부는 라벨의 불일치일 가능성이 있다. 이 데이터로 모델을 비교할 때는 국내 기관 자료만 사용하거나 기관을 통제하는 방법을 고려할 수 있다.

오차 분석 방법. 집단별 평균 오차만 보면 몽골어나 우즈베크어 학습자가 불리하게 예측된다고 판단하기 쉽지만, 급수 분포를 보정하면 차이가 대부분 사라졌다. 집단 간 공정성을 평가할 때는 실제 급수가 같은 학습자끼리 비교해야 한다는 점을 확인할 수 있었다.

표집 방식의 영향. 처음에는 검색 결과의 앞쪽 페이지만 수집하였는데, 결과가 모어 가나다순으로 정렬되어 있어 러시아어 7,197문장, 중국어 238문장으로 분포가 치우쳤다. 이 데이터로는 중국어·일본어 학습자가 1급 이상 낮게 예측된다는 결과가 나왔지만, 무작위 표집 후에는 나타나지 않았다. 원래 분포를 유지하는 표집이 분석 결과에 직접적인 영향을 준다는 것을 확인하였다.

모델별 역할. 예측 성능은 n-gram 모델이 높았지만, 급수에 따라 무엇이 달라지는지(문체 변화, 조사 사용 등)는 언어 특징을 통해 확인할 수 있었다. 성능과 해석 가능성을 함께 고려할 필요가 있으며, 근거를 함께 제시하는 LLM 기반 채점도 이러한 관점에서 비교해 볼 만하다.

한계. 첫째, 원본 말뭉치 전체가 아니라 검색 서비스를 통한 문장 표본을 사용했기 때문에 글 전체의 구조(담화, 문단 전개)는 분석하지 못하였다. 둘째, 검색어를 기준으로 표집하였으므로 문체 비율과 같은 빈도는 원래 분포와 다를 수 있다. 셋째, 자원 제약으로 BERT 계열 모델의 미세조정이나 LLM 기반 채점은 수행하지 않았다.

5. 결론

본 프로젝트에서는 한국어 학습자 말뭉치의 문어 28,971문장을 이용하여 학습자의 급수를 예측하였다. 문자·형태소 n-gram과 Ridge 회귀를 사용한 모델이 CPU 환경에서 QWK 0.642, ±1급 정확도 78.6%를 보였다. 주요 결과는 다음과 같다.

- 급수가 높아질수록 문장 길이, 조사 종류, 관형절 사용이 늘었고, 2급과 3급 사이에서 해요체·합니다체에서 한다체로의 문체 변화가 뚜렷하게 나타났다.
- 모어별 원시 오차는 대부분 급수 분포의 차이로 설명되었다. 반면 학습에서 제외된 모어에서는 성능이 낮아졌고(QWK 0.59에서 0.50), 텍스트만으로 모어를 53% 분류할 수 있었다.
- 국외 학습자의 급수는 글의 특성과 덜 일치하였으며, 라벨의 일관성이 성능의 한계에 영향을 주는 것으로 보인다.

향후에는 원본 말뭉치를 이용한 글 단위 예측, 오류 주석 말뭉치를 활용한 오류 유형별 분석, 기관 및 학습 환경을 고려한 라벨 정제, 한국어 사전학습 모델(KLUE-RoBERTa 등)의 미세조정과 LLM 기반 채점의 모어별 오차 비교를 진행할 수 있을 것이다.

참고문헌

Attali, Y., & Burstein, J. (2006). Automated essay scoring with e-rater® V.2. *Journal of Technology, Learning, and Assessment, 4*(3).

Dong, F., Zhang, Y., & Yang, J. (2017). Attention-based recurrent convolutional neural network for automatic essay scoring. In *Proceedings of CoNLL 2017* (pp. 153–162). ACL.

Hewlett Foundation. (2012). *The Hewlett Foundation: Automated Essay Scoring* [Data set]. Kaggle. https://www.kaggle.com/c/asap-aes

Lee, S., Cai, Y., Meng, D., Wang, Z., & Wu, Y. (2024). Unleashing large language models' proficiency in zero-shot essay scoring. In *Findings of EMNLP 2024* (pp. 181–198). ACL.

Li, S., & Ng, V. (2024). Automated essay scoring: A reflection on the state of the art. In *Proceedings of EMNLP 2024*. ACL.

Mizumoto, A., & Eguchi, M. (2023). Exploring the potential of using an AI language model for automated essay scoring. *Research Methods in Applied Linguistics, 2*(2), 100050.

Page, E. B. (1966). The imminence of grading essays by computer. *Phi Delta Kappan, 47*(5), 238–243.

Taghipour, K., & Ng, H. T. (2016). A neural approach to automated essay scoring. In *Proceedings of EMNLP 2016* (pp. 1882–1891). ACL.

국립국어원. 한국어 학습자 말뭉치 나눔터. https://kcorpus.korean.go.kr (2026. 10. 23. 접속)

Kiwi: 지능형 한국어 형태소 분석기 (kiwipiepy 0.24.1). https://github.com/bab2min/kiwipiepy

Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

소스 코드: https://github.com/zmfozj1231-eng/korean-learner-aes