문장은 학습자의 '급'을 얼마나 말해 주는가?

한국어 학습자 말뭉치를 이용한 숙달도 자동 예측과 모어(L1)별 편향 분석

자연어처리 Term Project #1 (Automated Essay Scoring) · 이재영 (학번: 1102643012) · 2026. 10. 23.

요약

본 프로젝트는 국립국어원 한국어 학습자 말뭉치에서 학습자가 쓴 문장만으로 작성자의 한국어 급수(1–6급)를 예측하는 간접 자동 채점 문제를 다룬다. 공개 검색 서비스에서 문어 28,971문장(18,909개 글, 75개 모어)을 급별로 균형 있게 무작위 표집하고, GPU 없이 재현 가능한 1세대형 언어 특징(Kiwi 형태소 분석 기반 25개)과 문자·형태소 n-gram을 Ridge 회귀로 비교했다. 학습자 단위 5-fold 교차검증에서 n-gram 모델이 QWK 0.642(±1급 정확도 78.6%)로 가장 좋았고, 길이 baseline은 0.182, 언어 특징은 0.412였다. 급이 오를수록 문장이 길어지고 조사·관형형 어미가 다양해지며, 특히 종결 문체가 2급→3급(TOPIK I→II 경계)에서 해요체·합니다체에서 한다체로 급격히 바뀌었다. 몽골어·우즈베크어 학습자는 0.7–0.8급 과대평가되는 것처럼 보였지만 급 분포를 보정하면 대부분 사라져, 원인이 모어가 아니라 극단 급을 중간으로 끌어당기는 '중간 점수 쏠림'임을 확인했다. 반면 해당 모어를 학습에서 빼면 QWK가 0.586에서 0.501로 떨어져, 작성자 집단이 바뀌면 채점 성능이 떨어진다는 AES의 일반화 문제가 모어 축에서도 재현되었다. 또 같은 1급이라도 국외 학습자의 글은 국내보다 0.7급 더 높게 예측되었다. 이는 '급'이라는 라벨이 기관과 환경마다 다른 의미를 가지며, 이것이 성능의 상한을 정한다는 것을 보여 준다.

1. 서론

자동 글쓰기 평가(Automated Essay Scoring, AES)는 사람 채점자의 판단을 재현하는 기술이다. 표면 특징과 선형 회귀를 쓰던 1세대(Page, 1966; Attali & Burstein, 2006), 신경망이 특징 설계를 대신한 2세대(Taghipour & Ng, 2016; Dong et al., 2017), 루브릭과 LLM으로 점수와 근거를 함께 만드는 3세대(Mizumoto & Eguchi, 2023; Lee et al., 2024)로 발전해 왔다. 그러나 어느 세대든 학습 데이터와 다른 집단·주제의 글이 들어오면 성능이 크게 떨어진다는 문제가 남아 있다(Li & Ng, 2024).

본 프로젝트에 배정된 국립국어원 한국어 학습자 말뭉치는 108개 언어권 성인 학습자의 글이고, 라벨은 글의 점수가 아니라 작성자의 한국어 급수(1–6급)다. 따라서 과제는 "이 글은 몇 점인가"가 아니라 "이 글을 쓴 사람은 몇 급인가"를 맞히는 간접 AES가 된다. 이 데이터에는 다른 AES 데이터에 없는 정보, 즉 작성자의 모어(L1)와 학습 환경이 있다. 같은 급이라도 모어마다 틀리는 지점과 문체가 다르므로, 이는 수업에서 다룬 주제 변화에 따른 성능 저하 문제를 작성자 집단의 변화라는 관점에서 살펴볼 수 있다.

본 연구의 질문은 다음 네 가지다.

- **RQ1.** 문장 하나로 학습자의 급을 얼마나 예측할 수 있는가? 어떤 표현 방식(표면 특징 vs. n-gram)이 유효한가?
- **RQ2.** 급이 오를수록 학습자의 한국어는 구체적으로 어떻게 달라지는가?
- **RQ3.** 예측기는 특정 모어·학습 환경의 학습자에게 체계적으로 유리하거나 불리한가?
- **RQ4.** 학습 때 보지 못한 모어의 학습자에게도 일반화되는가?

2. 방법

2.1 데이터 수집과 전처리

말뭉치 원본 파일은 국립국어원에 이용 신청했지만(접수번호 mfe-20261023-2) 승인에 1–2일이 걸려 마감 전에 받을 수 없었다. 그래서 같은 말뭉치의 공개 서비스인 '한국어 학습자 말뭉치 나눔터' 원시 말뭉치 검색을

이용했다. 검색 결과의 각 행은 (모어, 급수, 학습 환경, 표본 ID, 왼쪽 문맥 + 중심어 + 오른쪽 문맥)으로 구성되고, 문맥을 이어 붙이면 학습자가 쓴 한 문장이 된다.

- 조건: 문어(쓰기) 자료만 사용, 급수 1–6급 각각 별도로 검색 ('6급~'과 '정보 없음' 제외).
- 검색어: 급과 무관하게 자주 쓰이는 어절 18개 (예: `있습니다.`, `그래서`, `저는`, `때문에`, `한다.`).
- 표집: 검색어×급마다 결과 페이지(100행) 3개를 무작위로 추출. 처음에는 앞 페이지부터 수집했는데, 결과가 모어 가나다순으로 정렬되어 있어 러시아어·네덜란드어 등이 과대 표집되는 편향(러시아어 7,197문장 vs 중국어 238문장)을 발견해 무작위 페이지 추출로 바꾸었다.
- 정제: (표본 ID, 문장 번호) 기준 중복 제거, 5자 미만 문장 제거, 동일 문장 제거.

최종 데이터는 28,971문장, 18,909개 글(표본), 75개 모어이고, 급별로 4,032–5,185문장으로 거의 균형이다(그림 1). 학습 환경은 국내 19,803문장, 국외 9,168문장이다.

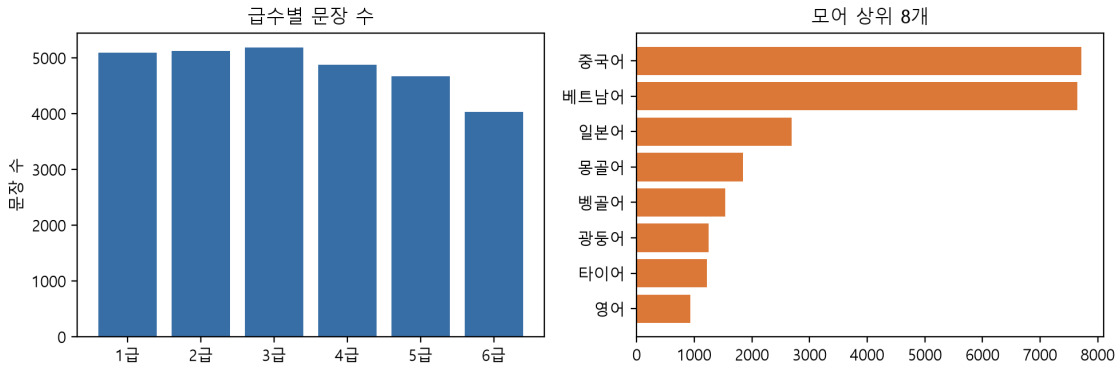


그림 1. 급수별 문장 수와 상위 8개 모어의 문장 수.

2.2 모델

수업 안내에 따라 GPU와 유료 API 없이 노트북 CPU에서 재현 가능한 모델만 사용했다. 모두 1–6급을 실수값으로 예측하는 회귀이며, 평가할 때 반올림해 1–6 범위로 자른다.

모델	입력 표현	회귀기
M0 길이 baseline	어절 수, 글자 수	Ridge (α=1)
M1 언어 특징	Kiwi 형태소 분석 기반 특징 25개: 길이, 형태소 TTR, 조사 종류 수, 연결어미(EC)·관형형 전성어미(ETM)·명사형 전성어미(ETN)·보조용언(VX)·의존명사(NNB) 비율, 종결 문체(합니다/해요/한다), 절 수, 어휘 희귀도 등	Ridge / HistGradientBoosting
M2 n-gram	문자 1–3gram TF-IDF + 형태소/품사 1–2gram TF-IDF (min_df=2, sublinear tf)	Ridge (α=1)
M3 결합	M2 + M1 (표준화)	Ridge (α=1)

형태소 분석기: kiwipiepy 0.24.1. 라이브러리: scikit-learn 1.9.1, numpy 2.5.3, pandas 3.1.0, scipy 1.18.1, Python 3.12.10.

2.3 실험 설계와 평가

- 교차검증: 5-fold GroupKFold. 같은 글(표본)의 문장이 학습과 평가에 동시에 들어가지 않도록 했다. TF-IDF 사전과 표준화는 매 폴드 학습 데이터로만 다시 학습했다. 비교를 위해 문장 단위 무작위 KFold도 함께 보고한다.
- 지표: AES 표준 지표인 Quadratic Weighted Kappa(QWK), 정확도, ±1급 정확도(Adj±1), MAE, Spearman ρ.
- E3 문장→글: 같은 글에서 문장 k개(k=1–4)의 예측을 평균했을 때 성능이 어떻게 변하는지 본다. 공정한 비교를 위해 문장이 4개 이상 수집된 같은 글 집합에서 k만 바꾸었고, 무작위 추출을 20회 반복해 평균했다.

- E4 편향: 모어별 평균 오차(예측−실제)를 계산한다. 모어마다 급 분포가 다르므로 급별 평균 오차를 전체 급 분포로 가중 평균한 '급 보정 편향'을 함께 보고한다. 학습 환경(국내/국외)별 편향도 같은 방식으로 본다.
- E5 특징 분석: 각 언어 특징과 급수의 Spearman 상관.
- E6 처음 보는 모어: 표본이 150문장 이상인 15개 모어마다 그 모어를 학습에서 완전히 뺀 모델(leave-one-L1-out)과 E1 교차검증 예측을 비교한다. 같은 n-gram 특징으로 모어 자체를 분류하는 실험도 함께 했다(15개 모어, GroupKFold, 로지스틱 회귀).

코드: https://github.com/zmfozj1231-eng/korean-learner-aes `src/collect.py`(수집), `src/features.py`(특징), `src/run_experiments.py`(실험 전체). 말뭉치 원문은 이용 약관에 따라 저장소에 포함하지 않았다.

3. 결과

3.1 RQ1: 문장 하나로 급을 얼마나 맞히는가

모델	분할	QWK	Acc	Adj±1	MAE	Spearman
길이 baseline (Ridge)	학습자 단위	0.182	0.192	0.570	1.333	0.380
언어 특징 25개 (Ridge)	학습자 단위	0.401	0.233	0.675	1.191	0.506
언어 특징 25개 (GBM)	학습자 단위	0.412	0.234	0.686	1.172	0.520
문자+형태소 n-gram (Ridge)	**학습자 단위**	**0.642**	**0.346**	**0.786**	**0.960**	**0.687**
n-gram + 언어 특징 (Ridge)	학습자 단위	0.642	0.345	0.785	0.960	0.687
언어 특징 25개 (Ridge)	무작위(문장)	0.401	0.233	0.675	1.192	0.506
문자+형태소 n-gram (Ridge)	무작위(문장)	0.651	0.349	0.791	0.948	0.696
n-gram + 언어 특징 (Ridge)	무작위(문장)	0.651	0.350	0.791	0.948	0.696

표 1. 문장 단위 급수 예측 성능 (5-fold CV, 28,971문장). 굵은 행이 최고 성능.

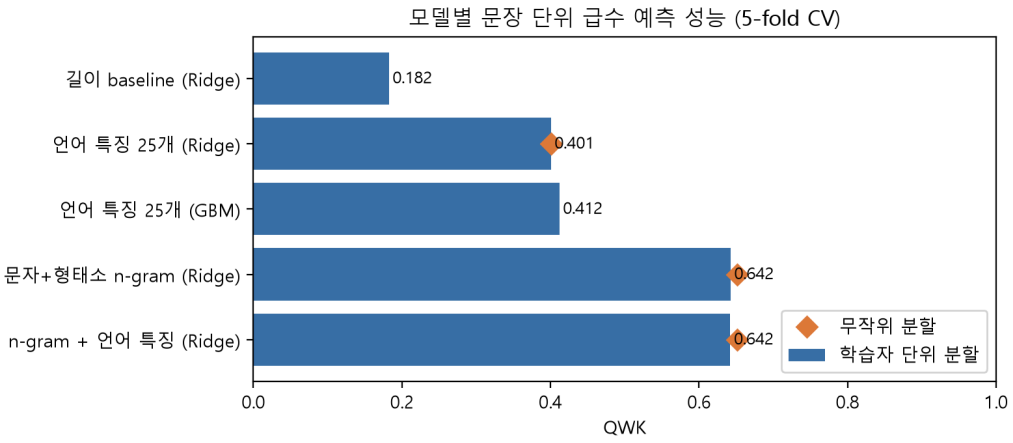


그림 2. 모델별 QWK. 주황 마름모는 무작위 분할 결과.

입력 표현에 따라 성능 차이가 컸다. 길이만 쓴 baseline(QWK 0.182)도 우연 수준보다는 높아, Page(1966) 이래 알려진 "길이가 점수를 상당 부분 설명한다"는 관찰이 학습자 데이터에서도 성립한다. 형태소 기반 특징 25개는 QWK를 0.40 수준으로 올렸고, 문자·형태소 n-gram은 0.642로 가장 높았다. n-gram에 언어 특징을 더해도 성능이 오르지 않았다(0.642). 언어 특징이 담는 정보(어미 종류, 문체, 길이)를 n-gram이 이미 포착하기 때문으로 보인다.

정확한 급을 맞히는 비율은 낮았지만 ±1급 이내 예측은 비교적 안정적이었다. 정확도는 34.6%(6급 우연 수준 16.7%)지만 ±1급 정확도는 78.6%다. 혼동행렬(그림 3)을 보면 예측이 2–5급에 몰리고, 1급(27%)과 6급(18%)은 양 끝에서 안쪽으로 끌려간다. 수업에서 LLM-as-a-Judge의 단점으로 다룬 '중간 점수 쏠림'이 회귀 모델에서도 같은 모양으로 나타난다.

데이터 분할 방식에 따른 차이는 작았다. 문장 단위 무작위 분할의 QWK가 학습자 단위 분할보다 0.009 높았다. 이번 표본은 글 하나에서 평균 1.5문장만 수집되어 같은 글의 문장이 양쪽에 들어갈 기회가 적었기 때문이다. 글 전체를 쓰는 원본 데이터라면 이 차이가 커질 것이므로, 학습자 단위 분할을 기본으로 삼았다.

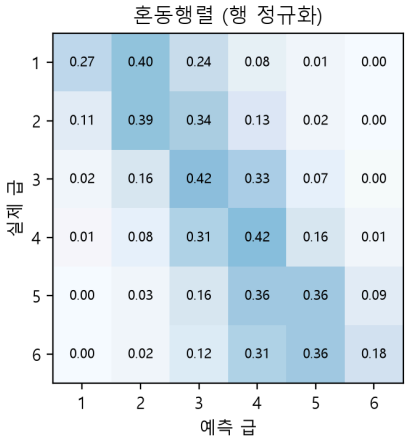


그림 3. 최고 모델(M2)의 혼동행렬 (행 정규화).

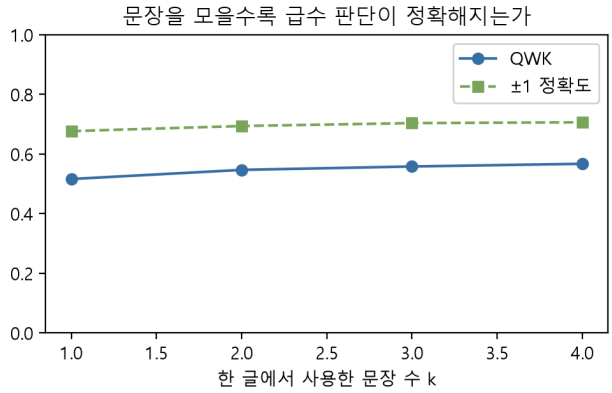


그림 4. 같은 글에서 문장 k개를 평균했을 때의 성능 (966개 글, 20회 평균).

한 글에서 사용하는 문장 수를 늘리면 성능이 조금씩 올랐다. 같은 966개 글에서 문장 1개만 보면 QWK 0.516, 4개를 평균하면 0.567(Spearman 0.589→0.696)로 올랐다. 다만 증가 폭은 k가 커질수록 줄었다. 같은 학습자의 문장은 서로 비슷한 정보를 담고 있고, 뒤에서 보듯 라벨 자체의 잡음이 상한을 만들기 때문이다.

3.2 RQ2: 급이 오르면 무엇이 달라지는가

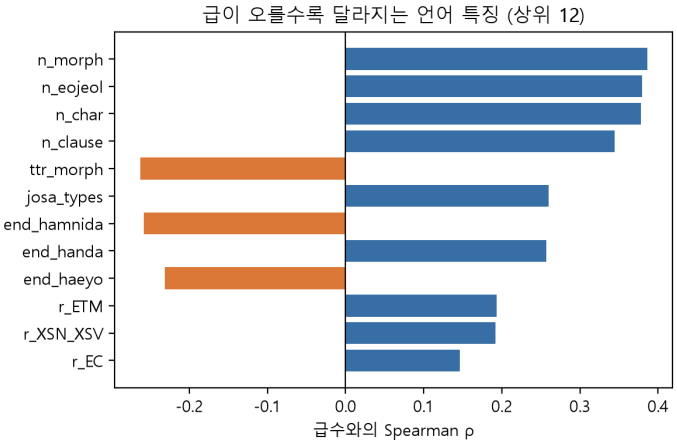


그림 5. 급수와 Spearman 상관이 큰 특징 12개.

특징	1급	3급	6급
어절 수 (ρ=+0.38)	7.3	9.81	13
조사 종류 수 (ρ=+0.26)	2.56	3.13	3.92
절 수(EC+ETM+1) (ρ=+0.34)	2.6	3.78	4.89
관형형 어미 비율 (ρ=+0.19)	0.0314	0.0485	0.0571
해요체 종결 (ρ=-0.23)	0.19	0.0411	0.0129
합니다체 종결 (ρ=-0.26)	0.614	0.417	0.252
한다체 종결 (ρ=+0.26)	0.116	0.38	0.474
형태소 TTR (ρ=-0.26)	0.943	0.909	0.879

표 2. 주요 특징의 급별 평균.

그림 5와 표 2는 학습자의 한국어가 급에 따라 어떻게 달라지는지 보여 준다.

- 길이와 구조: 어절 수(7.3→13.0), 절 수, 관형형 어미 비율이 꾸준히 증가한다. 1급은 "저는 몽골에 삽니다." 같은 단문, 6급은 관형절과 연결어미로 정보를 겹쳐 쌓는 복문을 쓴다.

- 조사의 다양화: 문장당 조사 종류가 2.6개에서 3.9개로 늘어난다(ρ=+0.26). 기본 격조사를 넘어 보조사와 복합 조사를 쓰기 시작한다는 뜻이다.
- 종결 문체 변화가 가장 컸다. 해요체 종결은 1급 19%→6급 1%, 한다체는 12%→47%로 바뀐다. 검색어 설계의 영향을 없애려고 중립 검색어(그래서, 저는, 때문에 등)로 모은 14,985문장만 다시 보았더니 경향이 더 뚜렷했다. 해요체는 36%→2%, 한다체는 7%→62%로 바뀌었고, 변화의 대부분이 2급→3급 사이에서 일어났다(한다체 23%→57%). 이 경계는 TOPIK I(1–2급)과 TOPIK II(3–6급)의 경계와 일치한다. TOPIK II 쓰기 시험이 한다체를 요구하므로, 이 변화는 '언어 능력'과 함께 시험과 교육과정이 만든 문체 규범을 반영한다.
- 어휘 특징: 어휘 희귀도(코퍼스 내 빈도 순위)는 급과 거의 상관이 없었고(ρ=+0.07), 형태소 TTR은 오히려 음의 상관이었다(ρ=−0.26). TTR은 문장이 길수록 기계적으로 낮아지므로, 문장 단위에서는 어휘 다양도가 길이 효과에 가려진다. 1세대 AES의 대표 특징인 어휘 다양도는 글 단위에서 써야 의미가 있다.

3.3 RQ3: 모어·학습 환경에 따른 편향

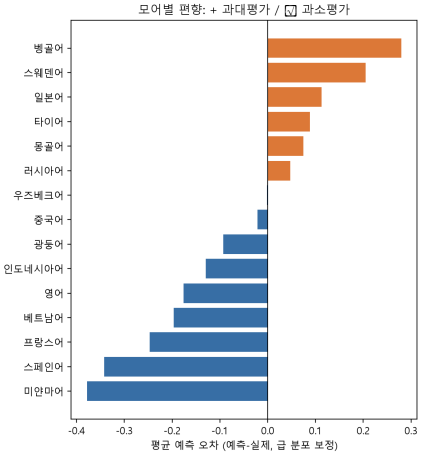


그림 6. 모어별 급 보정 편향.

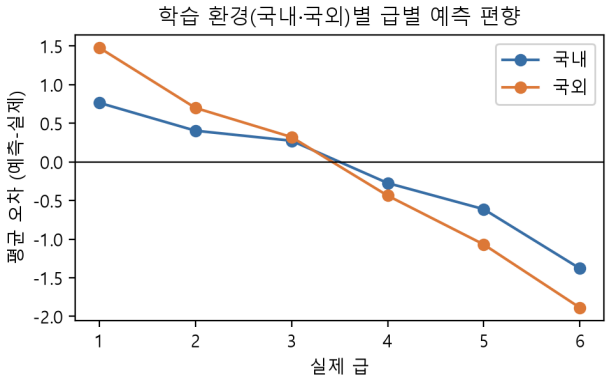


그림 7. 학습 환경별, 실제 급별 평균 오차.

모어	문장 수	평균 급	원시 편향	급 보정 편향	QWK
미얀마어	175	4.53	-1.07	-0.38	0.43
몽골어	1,848	2.46	+0.82	+0.07	0.43
우즈베크어	413	2.04	+0.71	-0.00	0.26
타이어	1,216	2.61	+0.66	+0.09	0.43
프랑스어	229	4.70	-0.51	-0.25	0.47
벵골어	1,535	2.00	+0.47	+0.28	0.06
러시아어	598	3.95	-0.43	+0.05	0.40

표 3. 원시 편향이 큰 모어들의 원시 편향과 급 보정 편향 비교.

모어별 원시 편향은 상당 부분 급 분포 차이로 설명되었다. 원시 편향만 보면 몽골어(+0.82급), 우즈베크어(+0.71), 타이어(+0.66) 학습자는 과대평가되고 미얀마어(−1.07)는 과소평가되는 것처럼 보인다. 그러나 이들 모어는 급 분포가 한쪽으로 치우쳐 있다(예: 우즈베크어 평균 2.0급, 벵골어 95%가 2급). 급별 오차를 전체 급 분포로 보정하면 몽골어 +0.07, 우즈베크어 0.00, 타이어 +0.09로 거의 사라진다. 즉 모델이 특정 모어를 차별한 것이 아니라, 낮은 급이 많은 집단은 위로, 높은 급이 많은 집단은 아래로 끌어당기는 중간 쏠림이 집단 수준에서 '편향'으로 보인 것이다. 보정 후에도 미얀마어(−0.38)와 스페인어(−0.34)에는 과소평가가 남았지만, 표본이 각 200문장 내외라 결론을 내리기에는 이르다.

학습 환경에 따른 차이는 보정 후에도 남았다. 같은 1급이라도 국외 학습자는 평균 +1.48급, 국내 학습자는 +0.76급으로 예측되고, 6급에서는 국외 -1.89, 국내 -1.38로 국외 쪽의 중간 쏠림이 더 강하다(그림 7). 국외 학습자의 급 라벨이 글의 특성과 덜 일관된다는 뜻이다. 오차가 가장 큰 사례(표 4)에도 "또한 생성형 AI인 챗봇은 고객 서비스를 향상하는 데 도움이 되고 있다."처럼 고급 문장을 쓴 국외 몽골어 '1급' 학습자가 여럿 있었다. 해외 기관의 반 배정 급이 국내 기관의 급, 혹은 TOPIK 급과 같은 척도가 아닐 가능성이 크다.

실제	예측	모어	문장
1	6.0	몽골어	또한 생성형 AI인 챗봇은 고객 서비스를 향상하는 데 도움이 되고 있다.
1	5.9	우르두어	인구 증가율이 높아지면서 자원 부족, 교육과 보건 서비스의 부족, 그리고 경제 발전의 어려움이 심각한 문제로 대두되고 있습니다.
6	1.2	중국어	나는 나의 집을 진짜 좋아한다.
6	1.5	몽골어	저는 몽골에 삽니다.
6	1.4	베트남어	나는 종아하는 한국에서 삽니다.

표 4. 오차가 가장 큰 사례. 위 두 개는 라벨 잡음으로 보이는 사례, 아래 세 개는 '문장 하나'라는 입력 단위의 한계(고급 학습자도 쉬운 문장을 쓴다)를 보여 주는 사례다.

3.4 RQ4: 처음 보는 모어

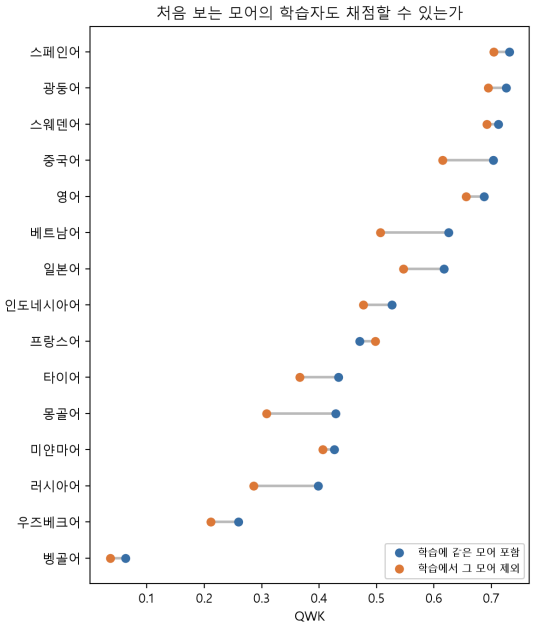


그림 8. 같은 모어 학습자가 학습 데이터에 있을 때(파랑)와 없을 때(주황)의 QWK.

학습에 포함되지 않은 모어에서는 성능이 낮아졌다. 15개 모어 전체(문장 수 가중 평균)에서 QWK가 0.586에서 0.501로 떨어졌다. 하락 폭이 큰 모어는 몽골어(0.43→0.31), 베트남어(0.63→0.51), 러시아어(0.40→0.29), 중국어(0.70→0.62)였다. 몽골어와 타이어는 학습에서 빠지면 과대평가가 각각 +0.82→+1.04, +0.66→+0.84로 커졌다. 반대로 영어, 스페인어, 스웨덴어처럼 표본이 적은 모어는 거의 영향이 없었는데, 원래부터 다른 모어의 데이터로 채점되고 있던 셈이기 때문이다.

이 결과와 관련해, 텍스트에 모어 정보가 얼마나 남아 있는지도 확인하였다. 같은 n-gram 특징으로 15개 모어를 분류했더니 정확도가 53.2%(다수 클래스 28.2%, macro-F1 0.30)였다. 학습자의 문장에는 모어의 흔적(전이 오류, 선호 구문, 고유명사)이 남아 있고, 급수 예측기는 이 흔적과 급의 결합 분포를 함께 학습한다. 따

라서 학습에 없던 모어가 들어오면 성능이 낮아지는 것으로 보인다. 수업에서 다룬, 주제가 바뀌면 채점 성능이 떨어지는 문제가 작성자 집단이 바뀌는 경우에도 비슷하게 나타난다고 볼 수 있다.

4. 논의

(1) 라벨의 성격. 라벨이 글의 질이 아니라 작성자의 소속 급이므로, 같은 6급 학습자도 쉬운 문장을 쓰면 낮게 예측된다(표 4). 이 오차는 모델의 실패라기보다 과제 정의의 한계다. 실제 교육 현장에서 쓰려면 글 단위 루브릭 점수가 있는 데이터(예: 국립국어원 글쓰기 채점 자료)로 보정하거나, 문장이 아니라 글 전체를 입력해야 한다. E3에서 문장을 모을수록 성능이 오른 것도 같은 방향을 가리킨다.

(2) 급 척도의 일관성. 국외 학습자에게서 중간 쏠림이 더 강하게 나타난 것은 기관마다 급을 매기는 기준이 다르다는 증거다. 성능이 QWK 0.64 근처에서 멈추는 이유 중 상당 부분은 모델이 아니라 라벨 잡음일 가능성이 크다. 따라서 이 데이터로 모델을 비교할 때는 국내 기관 표본만 쓰거나 기관을 통제 변수로 두는 것이 공정하다.

(3) 편향 분석 방법. 집단별 평균 오차만 보면 몽골어·우즈베크어 학습자가 '불리하다'고 잘못 결론 내리기 쉽다. 급 분포를 보정하자 편향의 대부분이 사라졌다. 공정성을 평가할 때는 같은 실제 점수끼리 비교해야 한다는 교훈이고, LLM 채점기의 집단 편향을 평가할 때도 그대로 적용된다.

(4) 표집 방식의 영향. 처음에는 검색 결과의 앞 페이지만 수집했는데, 결과가 모어 가나다순으로 정렬되어 있어 러시아어 문장은 7,197개, 중국어는 238개가 모였다. 이 데이터로 얻은 1차 결과에서는 "중국어·일본어 학습자가 1급 이상 과소평가된다"는 그럴듯한 결론이 나왔지만, 무작위 표집 뒤에는 사라졌다. 수업에서 언급된 분포를 유지하는 표집의 필요성을 실제로 확인할 수 있었다.

(5) 특징 기반 모델과 n-gram 모델의 역할. 형태소 분석 특징은 해석에, n-gram은 성능에 강했다. 성능만 원하면 n-gram 하나로 충분하지만, "급이 오르면 무엇이 변하는가"(문체 전환, 조사 다양화)라는 교육적으로 쓸모 있는 답은 해석 가능한 특징에서 나왔다. 3세대 LLM 채점기가 근거를 함께 내놓는 장점은 바로 이 부분을 노린 것이고, 2세대 모델의 성능과 1세대 특징의 해석력을 함께 얻는 방법이 실무에서 중요할 것이다.

한계. (1) 원본 말뭉치가 아니라 검색 서비스에서 얻은 문장 표본이므로 글 전체 구조(담화, 문단 전개)를 볼 수 없다. (2) 검색어 기반 표집이라 문장마다 특정 어절이 반드시 들어가 있고, 문체 비율 같은 절대 빈도는 원 분포와 다를 수 있다(중립 검색어 부분집합으로 일부 확인). (3) 비용 제약으로 BERT 파인튜닝이나 LLM 채점은 하지 않았다.

5. 결론

한국어 학습자 말뭉치의 문어 28,971문장으로 학습자의 급수를 예측한 결과, 문자·형태소 n-gram + Ridge가 CPU만으로 QWK 0.642, ±1급 정확도 78.6%를 얻었다. 주요 메시지는 세 가지다.

- 학습자의 한국어는 길이와 구조뿐 아니라 '문체'로 자란다. 2급→3급(TOPIK I→II)에서 해요체·합니다체가 한다체로 바뀌는 전환이 가장 강한 신호였다.
- 모어 편향처럼 보이는 것은 대부분 중간 쏠림의 급 분포 차이에 따른 효과다. 반면 처음 보는 모어에서는 성능이 실제로 떨어지고(QWK 0.59→0.50), 텍스트만으로 모어를 53% 맞힐 수 있을 만큼 모어의 흔적이 강하다.
- 성능의 상한은 모델보다 라벨이 정한다. 국외 학습자의 급은 글의 특성과 덜 일관되며, 이 데이터의 '급'은 글의 질이 아니라 기관이 매긴 소속 급이다.

향후 방향. (1) 승인된 원본 말뭉치로 글 단위 예측과 담화 특징 추가, (2) 오류 주석 말뭉치를 이용한 오류 유형별 특징(조사 오류, 어미 오류)과 모어별 전이 오류 분석, (3) 기관·환경을 통제한 라벨 정제, (4) 소형 한국어 인코더(KLUE-RoBERTa 등) 파인튜닝과 LLM zero-shot 채점의 모어별 편향 비교, (5) 모어 정보를 지우는 적대적 학습(adversarial debiasing)으로 처음 보는 모어에 대한 일반화 개선.

참고문헌

Attali, Y., & Burstein, J. (2006). Automated essay scoring with e-rater® V.2. *Journal of Technology, Learning, and Assessment, 4*(3).

Dong, F., Zhang, Y., & Yang, J. (2017). Attention-based recurrent convolutional neural network for automatic essay scoring. In *Proceedings of CoNLL 2017* (pp. 153–162). ACL.

Hewlett Foundation. (2012). *The Hewlett Foundation: Automated Essay Scoring* [Data set]. Kaggle. https://www.kaggle.com/c/asap-aes

Lee, S., Cai, Y., Meng, D., Wang, Z., & Wu, Y. (2024). Unleashing large language models' proficiency in zero-shot essay scoring. In *Findings of EMNLP 2024* (pp. 181–198). ACL.

Li, S., & Ng, V. (2024). Automated essay scoring: A reflection on the state of the art. In *Proceedings of EMNLP 2024*. ACL.

Mizumoto, A., & Eguchi, M. (2023). Exploring the potential of using an AI language model for automated essay scoring. *Research Methods in Applied Linguistics, 2*(2), 100050.

Page, E. B. (1966). The imminence of grading essays by computer. *Phi Delta Kappan, 47*(5), 238–243.

Taghipour, K., & Ng, H. T. (2016). A neural approach to automated essay scoring. In *Proceedings of EMNLP 2016* (pp. 1882–1891). ACL.

국립국어원. 한국어 학습자 말뭉치 나눔터. https://kcorpus.korean.go.kr (2026. 10. 23. 접속)

Kiwi: 지능형 한국어 형태소 분석기 (kiwipiepy 0.24.1). https://github.com/bab2min/kiwipiepy

Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.